

머신러닝

DAY2

분류 평가와 결정트리

정확도 하나로는 틀린 이유와 틀린 비용을 알 수 없다.

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-12 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

불균형 분류에서 혼동행렬을 출발점으로 정밀도, 재현율, F1, ROC-AUC를 연결한다. 이어서 결정트리가 경계를 만드는 방식과 과적합을 제어하는 파라미터를 해석한다.

오늘의 핵심 질문

정확도 하나로는 틀린 이유와 틀린 비용을 알 수 없다.

문제 해결 흐름

1 오류 비용 정의	2 확률 예측	3 임계값 적용	4 혼동행렬 계산	5 업무 목적에 맞는 지표 선택
---------------	------------	-------------	--------------	-------------------------

핵심 키워드

혼동행렬	Precision / Recall	Threshold	ROC-AUC	Tree pruning
------	--------------------	-----------	---------	--------------

2. 핵심 개념

혼동행렬

TN, FP, FN, TP 네 칸이 모든 분류 지표의 재료다. 실제 양성을 놓친 FN과 정상 대상을 잘못 경고한 FP의 비용이 문제마다 다르다.

정밀도와 재현율

정밀도는 양성이라고 예측한 것 중 맞은 비율, 재현율은 실제 양성 중 찾아낸 비율이다. 사기.질병처럼 놓침이 비싼 문제는 재현율을 우선하되 오탐 비용과 함께 본다.

임계값

predict_proba의 양성 확률을 어디서 자를지에 따라 정밀도와 재현율이 움직인다. 임계값은 모델 파라미터가 아니라 운영 정책에 가깝다.

ROC-AUC와 PR 관점

ROC-AUC는 임계값 전체에서 양성과 음성의 순위를 얼마나 잘 구분하는지 본다. 양성이 매우 드물면 Precision-Recall 곡선이 실제 양성 성능을 더 직접적으로 보여준다.

결정트리 규제

트리는 질문을 반복해 공간을 나눈다. max_depth, min_samples_split, min_samples_leaf로 너무 세밀한 분할을 막아 일반화 성능을 높인다.

3. 기법 비교와 선택

지표	질문	강점	주의점
Accuracy	전체 중 몇 개를 맞혔나?	클래스 균형과 오류 비용이 비슷할 때 직관적	불균형 데이터에서는 다수 클래스만 맞혀도 높음
Precision	경고 중 진짜는 얼마인가?	오탐 비용이 큰 스팸, 자동 차단 등에 중요	재현율을 낮추며 높아질 수 있음
Recall	실제 양성을 얼마나 찾았나?	질병, 사기처럼 누락 비용이 큰 문제에 중요	경고 수와 오탐이 늘 수 있음
F1	정밀도와 재현율의 균형은?	두 지표를 하나로 비교할 때 유용	업무 비용을 직접 반영하지는 않음
ROC-AUC	양성을 음성보다 위에 둘 확률은?	임계값 독립적인 순위 성능	극심한 불균형에서는 PR-AUC도 함께 확인

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_정확도_ROC_AUC	더미 분류기가 양성을 전혀 예측하지 않아 정밀도가 정의되지 않는 상황 확인	높은 정확도라도 소수 클래스를 완전히 놓칠 수 있다는 경고
01_정확도_ROC_AUC	임계값 0.40~0.60을 바꾸며 정밀도와 재현율 비교	모델 선택과 운영 임계값 선택을 분리해서 생각
02_피마인디언당뇨병 예측	Glucose 등 비현실적인 0값을 평균으로 보정하고 표준화	결측 의미를 가진 0은 단순 숫자가 아니라 데이터 품질 문제
03_결정트리	min_samples_leaf와 max_depth를 조정하고 GridSearchCV 수행	학습 정확도보다 교차검증과 테스트 성능으로 복잡도를 선택

4. 실전 적용 기준

판단 체크리스트

놓치면 위험한 양성이라면 재현율 목표를 먼저 정하고 정밀도를 확인한다.

자동 차단처럼 오탐 비용이 크면 정밀도를 우선하고 사람이 재검토할 수 있는지 본다.

트리 시각화는 규칙 설명에 좋지만 깊어질수록 해석과 일반화가 동시에 나빠진다.

임계값은 검증 데이터에서 정하고 테스트 데이터는 최종 확인에만 사용한다.

최소 코드 패턴

```
prob = model.predict_proba(X_valid)[:, 1]
pred = (prob >= threshold).astype(int)
print(confusion_matrix(y_valid, pred))
print(precision_score(y_valid, pred), recall_score(y_valid, pred))
print(roc_auc_score(y_valid, prob))
```

→ ROC-AUC에는 0/1 예측이 아니라 확률을 전달한다.

→ threshold는 업무 비용과 목표 재현율을 기준으로 검증 데이터에서 정한다.

5. 실수 방지와 복습

자주 생기는 오류

- 정확도가 가장 높은 임계값을 자동으로 선택하기
- 테스트 데이터로 임계값을 반복 조정하기
- 0으로 기록된 측정값을 실제 0으로 간주하기
- 결정트리의 학습 정확도가 1.0인 것을 좋은 모델의 증거로 보기

스스로 설명해 보기

- ☐ FP와 FN 중 어떤 오류가 더 비싼지 문제별로 설명할 수 있는가?
- ☐ 임계값을 낮추면 정밀도와 재현율이 일반적으로 어떻게 변하는가?
- ☐ ROC-AUC 계산에 확률이 필요한 이유는 무엇인가?
- ☐ min_samples_leaf가 트리 경계에 주는 효과는 무엇인가?

DAY 핵심 요약

1	분류 평가는 숫자 하나가 아니라 오류 비용을 표현하는 과정이다.
2	확률 모델과 임계값 정책을 분리하면 운영 목적에 맞게 조정할 수 있다.
3	트리는 규제로 질문 수를 제한할 때 설명력과 일반화의 균형이 좋아진다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.