

머신러닝

DAY5

회귀 모델과 오차 해석

회귀 점수는 얼마나 틀렸는지와 어떤 패턴을 놓쳤는지를 함께 말해 주어야 한다.

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-18 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

선형회귀에서 시작해 다항 특성, Ridge/Lasso, 트리 기반 회귀로 확장한다. MAE, RMSE, R2의 단위와 민감도를 구분하고 잔차와 교차검증으로 모델을 읽는다.

오늘의 핵심 질문

회귀 점수는 얼마나 틀렸는지와 어떤 패턴을 놓쳤는지를 함께 말해 주어야 한다.

문제 해결 흐름

1 기준선 예측	2 교차검증	3 잔차 확인	4 변환/규제	5 복잡도 대비 개선 판단
-------------	-----------	------------	------------	----------------------

핵심 키워드

Residual	MAE / RMSE	R2	Regularization	Feature transform
----------	------------	----	----------------	-------------------

2. 핵심 개념

잔차

잔차는 실제값 - 예측값이다. 평균이 0에 가깝다는 것만으로 충분하지 않으며 예측값 구간에 따라 부채꼴, 곡선, 집단 패턴이 남는지 확인한다.

MAE와 RMSE

MAE는 평균적인 절대 오차로 해석이 쉽고 RMSE는 큰 오차에 더 큰 벌점을 준다. 둘 다 목표변수와 같은 단위이므로 업무 규모와 연결하기 좋다.

R2

평균만 예측하는 기준선보다 변동을 얼마나 설명했는지 나타낸다. 1에 가까울수록 좋지만 데이터 범위가 다르면 직접 비교하기 어렵고 음수가 될 수도 있다.

규제

Ridge는 계수를 작게, Lasso는 일부 계수를 0으로 만든다. 규제는 스케일에 민감하므로 StandardScaler와 Pipeline으로 묶는 것이 안전하다.

비선형성과 변환

PolynomialFeatures, 로그 변환, 트리 모델은 곡선 관계를 표현한다. 표현력이 커질수록 교차검증으로 과적합을 확인해야 한다.

3. 기법 비교와 선택

지표	의미	큰 오차 민감도	사용 포인트
MAE	절대 오차의 평균	선형	평균적으로 얼마를 틀리는지 설명
RMSE	제곱 오차 평균의 제곱근	큼	큰 실수를 더 강하게 억제
R2	평균 기준선 대비 설명력	간접적	상대적 적합도 확인, 오차 크기는 별도 지표 필요
CV RMSE	여러 분할의 RMSE	큼	평균과 fold 간 편차로 일반화 안정성 확인

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_회귀	회귀 모델과 규제 강도를 교차검증 RMSE로 비교	대표 평균 RMSE 약 0.746이며 alpha에 따른 변화는 데이터와 스케일 맥락에서 해석
01_회귀	다항 회귀에서 차수가 늘 때 곡선 적합 비교	훈련 적합 향상과 검증 성능 저하를 분리해 과적합 확인
02_회귀	트리 기반 모델과 GridSearchCV, 일부 비정상 조합은 nan 경고	탐색공간은 유효한 파라미터 조합만 포함해야 함
회귀_김양일	모델 개선 과정에서 R2 약 0.217 -> 0.536 -> 0.953 수준으로 상승	MAE와 RMSE도 함께 감소했는지 확인해야 개선이 일관됨

4. 실전 적용 기준

판단 체크리스트

목표변수 단위로 설명해야 하면 MAE와 RMSE를 우선 보고 R2를 보조로 쓴다.

큰 오차가 특히 위험하면 RMSE를 모델 선택 지표로 둔다.

규제 회귀 전에는 수치 특성을 스케일링한다.

모델을 바꾼 뒤 잔차 패턴이 줄었는지 확인해 놓친 비선형성이나 집단 차이를 찾는다.

최소 코드 패턴

```
model = Pipeline([
    ("scale", StandardScaler()),
    ("reg", Ridge())
])
params = {"reg__alpha": [0.01, 0.1, 1, 10, 100]}
search = GridSearchCV(model, params, cv=5,
                       scoring="neg_root_mean_squared_error")
```

→ scikit-learn은 손실을 최대화 규칙에 맞추기 위해 음수 점수를 반환하므로 최종 해석 때 부호를 되돌린다.

→ alpha는 단독 숫자가 아니라 스케일링과 함께 해석한다.

5. 실수 방지와 복습

자주 생기는 오류

- R2만 보고 실제 오차 단위를 확인하지 않기
- 규제 모델에 스케일이 다른 특성을 그대로 넣기
- 다항 차수를 훈련 점수만으로 선택하기
- GridSearchCV의 nan 경고를 무시하고 최고 점수만 사용하기

스스로 설명해 보기

- ☐ RMSE가 MAE보다 큰 이유와 두 지표 차이가 커지는 상황은 무엇인가?
- ☐ R2가 음수가 될 수 있는 이유는 무엇인가?
- ☐ Ridge와 Lasso가 계수에 주는 영향은 어떻게 다른가?
- ☐ 잔차 그래프에서 부채꼴 모양은 어떤 문제를 암시하는가?

DAY 핵심 요약

1	회귀 평가는 오차의 크기, 큰 오류의 위험, 설명력을 함께 본다.
2	규제는 스케일링과 교차검증이 결합될 때 의미가 있다.
3	모델 개선은 점수뿐 아니라 잔차 패턴이 사라지는지로 확인한다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.