

머신러닝

DAY6

주택가격 예측 파이프라인

열이 많고 결측치와 범주형이 섞인 표 데이터는 어떻게 안정적으로 예측할까?

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-19 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

House Prices 형태의 실전 회귀에서 결측치, 범주형 인코딩, train/test 열 정렬, 로그 변환, XGBoost와 LightGBM 비교를 하나의 파이프라인으로 정리한다.

오늘의 핵심 질문

열이 많고 결측치와 범주형이 섞인 표 데이터는 어떻게 안정적으로 예측할까?

문제 해결 흐름

1 ID/목표 분리	2 타입별 결측 처리	3 범주형 인코딩	4 열 정렬	5 교차검증과 제출 예측
---------------	----------------	--------------	-----------	---------------------

핵심 키워드

Missing value	One-Hot	Log target	XGBoost	Train-test alignment
---------------	---------	------------	---------	----------------------

2. 핵심 개념

결측치는 타입별로

수치형은 중앙값, 범주형은 최빈값 또는 Missing 범주가 기본 출발점이다. 결측 자체가 의미를 가지는 열은 무조건 평균으로 채우지 않는다.

열 정렬

train과 test를 따로 One-Hot 하면 열 구성이 달라질 수 있다. ColumnTransformer를 학습 데이터에 fit하거나 변환 후 align을 사용해 동일한 입력 공간을 보장한다.

목표 로그 변환

주택가격처럼 오른쪽 꼬리가 긴 목표는 $\log_{10}$ 로 학습하면 고가 주택의 큰 절대오차 영향과 이분산성이 완화될 수 있다. 예측은 $\expm1$ 로 원 단위에 복원한다.

트리 부스팅

XGBoost와 LightGBM은 비선형 상호작용을 잘 잡지만 결측 처리와 범주 인코딩, 검증 설계가 여전히 중요하다. 모델 이름보다 파이프라인 일관성이 우선이다.

평가 단위

원 가격에서 RMSE를 계산하면 큰 금액 오차를 강하게 벌한다. 로그 RMSE는 상대적 비율 오차에 가까운 관점을 제공한다. 목적에 맞게 선택한다.

3. 기법 비교와 선택

단계	수치형	범주형	검증 포인트
결측 처리	median	most_frequent 또는 Missing	test 정보로 대체값을 계산하지 않음
변환	필요 시 log1p/scale	OneHotEncoder	모든 fold 안에서 fit
모델	XGBoost/LightGBM	인코딩 후 동일 입력	early stopping 검증과 test 분리
예측 복원	expm1	해당 없음	원 단위와 로그 단위 지표를 혼동하지 않음

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_회귀	주택 데이터 구조, 결측치, 중복 열과 train/test 차이 확인	모델보다 먼저 스키마와 데이터 품질을 검증
01_회귀	XGBoost 평가	MAE 약 17,531, RMSE 약 27,804, R2 약 0.899
01_회귀	LightGBM 평가	MAE 약 17,173, RMSE 약 28,927, R2 약 0.891
02_회귀	회귀 모델과 파라미터를 실행 결과 없이 구조 중심으로 정리	미실행 셀의 주장은 성능 결과로 간주하지 않고 재실행 후 검증

4. 실전 적용 기준

판단 체크리스트

비교에서는 RMSE와 R2가 같은 방향인지 확인하되 목적 지표를 하나 정한다.

현재 결과에서는 XGBoost가 RMSE와 R2, LightGBM이 MAE에서 근소하게 유리해 오류 비용에 따라 선택이 달라진다.

가격 분포가 긴 꼬리라면 로그 목표 모델을 기준선과 비교한다.

최종 예측 전 train/test 특성 이름과 순서를 자동 검증한다.

최소 코드 패턴

```
prep = ColumnTransformer([
    ("num", SimpleImputer(strategy="median"), num_cols),
    ("cat", Pipeline([
        ("fill", SimpleImputer(strategy="most_frequent")),
        ("onehot", OneHotEncoder(handle_unknown="ignore"))
    ]), cat_cols)
])
model = Pipeline([("prep", prep), ("reg", LGBMRegressor())])
```

→ ColumnTransformer가 열 선택, 결측 처리, 인코딩을 한 번에 고정한다.

→ Pipeline을 교차검증에 넘기면 각 fold에서 대체값과 범주 사전이 다시 학습된다.

5. 실수 방지와 복습

자주 생기는 오류

- train과 test를 각각 get_dummies한 뒤 열 차이를 방지하기
- 전체 데이터의 중앙값으로 결측치를 채운 뒤 교차검증하기
- 로그로 학습한 예측을 expm1 없이 가격으로 해석하기
- 미실행 노트북 셀을 실제 검증 결과로 기록하기

스스로 설명해 보기

- ☐ 범주형 인코딩 후 train/test 열이 달라지는 이유는 무엇인가?
- ☐ 가격 목표에 log1p를 적용하면 어떤 오차에 덜 민감해지는가?
- ☐ 현재 XGBoost와 LightGBM 결과에서 지표별 선택이 달라지는 이유는 무엇인가?
- ☐ ColumnTransformer와 Pipeline을 함께 쓰는 장점은 무엇인가?

DAY 핵심 요약

1	실전 표 데이터에서는 스키마 일관성과 누수 방지가 모델 선택보다 먼저다.
2	평가 단위가 원 가격인지 로그 가격인지 명확히 기록한다.
3	근소한 점수 차이보다 재현 가능한 전처리와 검증이 더 오래가는 개선이다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.