

머신러닝

DAY3

앙상블과 하이퍼파라미터 탐색

여러 약한 판단을 어떻게 결합해야 한 모델보다 안정적일까?

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-13 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

Voting, Random Forest, Gradient Boosting을 큰 구조로 구분하고 XGBoost와 LightGBM의 조기 종료를 이해한다. Hyperopt는 무작정 조합을 나열하는 대신 탐색 이력을 이용해 다음 후보를 고른다.

오늘의 핵심 질문

여러 약한 판단을 어떻게 결합해야 한 모델보다 안정적일까?

문제 해결 흐름

1 기준 모델 만들기	2 검증 방식 고정	3 탐색공간 정의	4 조기 종료로 학습	5 최종 모델 재평가
----------------	---------------	--------------	----------------	----------------

핵심 키워드

Voting	Bagging	Boosting	Early stopping	Hyperopt
--------	---------	----------	----------------	----------

2. 핵심 개념

Voting

서로 다른 모델의 예측을 투표한다. Hard voting은 클래스, Soft voting은 확률 평균을 사용한다. 모델의 오류 패턴이 다를수록 결합 이득이 크다.

Bagging과 Random Forest

여러 부트스트랩 표본과 무작위 특성으로 트리를 독립적으로 학습해 분산을 줄인다. 병렬화가 쉽고 강한 기준 모델로 쓰기 좋다.

Boosting

이전 모델이 놓친 부분에 다음 모델이 집중하며 순차적으로 보정한다. 높은 성능을 내기 쉽지만 학습률, 트리 깊이, 반복 수의 균형이 중요하다.

조기 종료

검증 손실이 일정 횟수 동안 개선되지 않으면 학습을 멈춘다. `n_estimators`를 크게 두되 실제 최적 반복 수는 검증 데이터가 결정하게 한다.

Hyperopt

탐색공간과 목적함수를 정의하고 Trials에 결과를 누적한다. 목적함수는 최소화되므로 AUC를 높이고 싶다면 `-AUC` 같은 형태로 반환한다.

3. 기법 비교와 선택

기법	핵심 아이디어	장점	주의점
Soft Voting	확률을 평균	서로 다른 모델을 간단히 결합	확률 보정과 모델 다양성이 필요
Random Forest	병렬 트리 평균	안정적이고 전처리 민감도가 낮음	큰 숲은 메모리와 예측 비용 증가
XGBoost	정규화된 순차 부스팅	세밀한 제어와 강한 성능	파라미터가 많고 학습 비용이 큼
LightGBM	leaf-wise 성장과 histogram	대용량에서 빠르고 효율적	작은 데이터에서 복잡함 앞이 과적합 가능
Hyperopt	이력 기반 확률 탐색	큰 연속 탐색공간에 효율적	목적함수와 검증 설계가 잘못되면 빠르게 잘못된 답 탐색

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_양상블	Logistic Regression과 KNN의 soft voting, Random Forest, Gradient Boosting 비교	단일 점수보다 모델 간 오류 다양성이 양상블 가치의 핵심
02_XGBoost	Native API와 Wrapper API, logloss 모니터링, early stopping	train과 validation 손실의 간격으로 과적합을 읽음
03_LightGBM	검증 점수 개선이 없을 때 학습 중단과 중요도 시각화	No further splits 경고는 추가 분할 이득이 없다는 뜻이며 무조건 오류는 아님
04_hyperopt	간단한 수학 목적함수에서 XGBoost 탐색으로 확장	자료의 탐색에서는 최고 loss가 약 -0.9649로 기록됨

4. 실전 적용 기준

판단 체크리스트

모델 간 예측이 매우 비슷하면 voting 이득이 작으므로 다양성을 먼저 확인한다.

부스팅은 learning_rate를 낮추면 보통 더 많은 트리가 필요하다.

early stopping용 검증 데이터와 최종 테스트 데이터를 구분한다.

탐색 후 최고 파라미터는 같은 교차검증 또는 고정된 테스트 세트에서 다시 검증한다.

최소 코드 패턴

```
model = XGBClassifier(n_estimators=2000, learning_rate=0.03,
                      max_depth=4, early_stopping_rounds=50,
                      eval_metric="logloss")
model.fit(X_train, y_train, eval_set=[(X_valid, y_valid)], verbose=False)
test_auc = roc_auc_score(y_test, model.predict_proba(X_test)[:, 1])
```

→ 큰 n_estimators는 최대 허용치이고 실제 반복 수는 early stopping이 정한다.

→ 테스트 세트는 파라미터 선택에 관여하지 않고 마지막 성능 확인에만 사용한다.

5. 실수 방지와 복습

자주 생기는 오류

- 테스트 점수를 Hyperopt 목적함수로 사용하기
- 학습률과 트리 수를 독립적으로 해석하기
- 특성 중요도를 인과관계로 해석하기
- 같은 유형의 모델만 모아 앙상블하면 자동으로 좋아진다고 가정하기

스스로 설명해 보기

- ☐ Bagging과 Boosting의 학습 순서 차이는 무엇인가?
- ☐ Soft voting이 hard voting보다 유리한 조건은 무엇인가?
- ☐ early stopping에 별도 검증 세트가 필요한 이유는 무엇인가?
- ☐ Hyperopt에서 AUC를 최대화하려면 목적함수 값을 어떻게 반환해야 하는가?

DAY 핵심 요약

1	앙상블의 힘은 모델 수가 아니라 서로 다른 오류의 결합에서 나온다.
2	부스팅의 핵심 제어축은 트리 복잡도, 학습률, 반복 수다.
3	탐색 알고리즘보다 누수 없는 검증 설계가 먼저다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.