

머신러닝

DAY4

불균형 데이터와 실전 앙상블

양성이 드문 문제에서 99.9% 정확도는 좋은 소식일까?

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-14 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

산탄데르 고객불만과 신용카드 사기처럼 양성이 드문 문제를 다룬다. 정확도 착시를 피하고 ROC-AUC, 정밀도, 재현율을 함께 보며 스케일링, 이상치 처리, 앙상블을 실전 흐름으로 연결한다.

오늘의 핵심 질문

양성이 드문 문제에서 99.9% 정확도는 좋은 소식일까?

문제 해결 흐름

1 클래스 비율 확인	2 층화 분리	3 기준 모델 평가	4 전처리/불균형 전략	5 임계값과 운영비용 결정
----------------	------------	---------------	-----------------	-------------------

핵심 키워드

Class imbalance	ROC-AUC	Outlier	Scale	Stacking
-----------------	---------	---------	-------	----------

2. 핵심 개념

불균형의 본질

다수 클래스를 맞추는 쉬운 전략이 정확도를 지배한다. 평가와 학습 모두 소수 클래스의 신호를 보존하도록 설계해야 한다.

순위와 임계값

ROC-AUC는 확률의 순위 품질, 정밀도와 재현율은 특정 임계값의 운영 결과다. 좋은 AUC가 자동으로 좋은 재현율을 보장하지 않는다.

스케일과 이상치

로지스틱 회귀는 입력 스케일의 영향을 받는다. 금액 분포처럼 긴 꼬리는 로그 변환이나 RobustScaler가 도움이 될 수 있고, 이상치 제거는 반드시 업무 의미를 확인한다.

불균형 학습

class_weight, under/over-sampling, 임계값 조정은 서로 다른 도구다. 재표본화는 학습 fold 안에서만 수행해 검증 데이터 복제 누수를 막는다.

Stacking

여러 기반 모델의 out-of-fold 예측을 새 특성으로 만들어 메타 모델이 조합한다. 기반 모델을 학습한 데이터의 예측을 그대로 쓰면 심각한 누수가 생긴다.

3. 기법 비교와 선택

전략	무엇을 바꾸나	언제 유용한가	핵심 주의점
class_weight	손실에서 소수 클래스 가중치	빠른 기준선과 선형/트리 모델	확률 보정이 달라질 수 있음
Over-sampling	소수 클래스 학습 표본 증가	소수 패턴 학습이 부족할 때	분할 전 수행하면 중복 누수
Under-sampling	다수 클래스 표본 축소	다수 데이터가 매우 많을 때	유용한 정상 패턴을 버릴 수 있음
Threshold 조정	배포 시 양성 판정 기준	비용과 목표 재현율이 명확할 때	모델 자체의 순위 성능은 바뀌지 않음
Stacking	모델 예측을 메타 특성으로 사용	오류 패턴이 다른 모델이 있을 때	반드시 out-of-fold 예측 사용

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_산탄데르	불만 고객 비율 확인 후 XGBoost와 LightGBM을 ROC-AUC로 튜닝	정확도 대신 회소 양성의 순위 성능을 중심으로 모델 선택
02_신용카드	기본 로지스틱 회귀 결과	정확도 0.9991이지만 정밀도 0.8304, 재현율 0.6284, F1 0.7154로 양성 성능은 별도 해석 필요
02_신용카드	스케일링, 금액 분포, 이상치와 LightGBM 비교	전처리 효과는 동일한 분할과 지표에서 비교해야 함
03_스태킹	여러 기반 분류기의 예측을 최종 모델 입력으로 결합	기반 예측 생성 방식이 메타 모델의 신뢰성을 결정

4. 실전 적용 기준

판단 체크리스트

사기 누락 비용과 정상 고객 차단 비용을 금액 또는 운영시간으로 정의한다.

층화 분할로 train/test의 양성 비율을 유지한다.

AUC로 순위를 비교한 뒤 검증 데이터에서 목표 재현율에 맞는 임계값을 정한다.

Stacking은 단일 모델보다 복잡하므로 단순 기준선 대비 개선폭이 배포 비용을 정당화하는지 본다.

최소 코드 패턴

```
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=42)
prob = cross_val_predict(model, X, y, cv=cv, method="predict_proba")[:, 1]
precision, recall, threshold = precision_recall_curve(y, prob)
# 목표 재현율을 만족하는 구간에서 정밀도가 가장 높은 임계값 선택
```

→ out-of-fold 확률은 학습 표본을 직접 본 모델의 예측이 아니므로 임계값 검토에 더 안전하다.

→ 최종 임계값은 업무 처리 용량과 오류 비용을 함께 반영한다.

5. 실수 방지와 복습

자주 생기는 오류

- 0.9991 정확도를 모델 완성의 근거로 보기
- 재표본화를 데이터 분할 전에 적용하기
- 테스트 세트에서 이상치 기준과 임계값을 반복 조정하기
- Stacking 기반 모델의 학습 예측을 메타 모델 입력으로 쓰기

스스로 설명해 보기

- ☐ 정확도와 재현율이 동시에 매우 다르게 보일 수 있는 이유는 무엇인가?
- ☐ ROC-AUC와 특정 임계값의 F1은 무엇을 다르게 측정하는가?
- ☐ Over-sampling은 파이프라인의 어느 위치에서 수행해야 하는가?
- ☐ Stacking에서 out-of-fold 예측이 필요한 이유는 무엇인가?

DAY 핵심 요약

1	희소 양성 문제의 평가는 다수 클래스가 아니라 놓침과 오탐의 비용에서 출발한다.
2	순위 모델 선택과 임계값 정책 결정을 분리한다.
3	복잡한 앙상블은 누수 없는 예측 생성이 보장될 때만 의미가 있다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.