

머신러닝

DAY7

차원축소와 고객 군집화

고차원 데이터를 잃지 않고 줄이고, 정답 없는 집단을 어떻게 설명할까?

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-20 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

PCA, LDA, SVD, NMF의 목적을 구분하고 K-Means, Mean Shift, 실루엣 평가를 연결한다. 온라인 소매 데이터에서는 RFM 특성으로 고객 행동을 요약한 뒤 군집을 해석한다.

오늘의 핵심 질문

고차원 데이터를 잃지 않고 줄이고, 정답 없는 집단을 어떻게 설명할까?

문제 해결 흐름

1 목적에 맞는 특성 구성	2 스케일/분포 변환	3 차원축소	4 군집 수 평가	5 원 단위로 군집 해석
----------------------	----------------	-----------	--------------	---------------------

핵심 키워드

PCA	LDA / SVD / NMF	K-Means	Silhouette	RFM
-----	-----------------	---------	------------	-----

2. 핵심 개념

PCA

분산이 큰 직교 방향을 찾는 비지도 선형 변환이다. 스케일이 큰 특성이 분산을 지배하므로 표준화 여부가 결과를 크게 바꾼다.

LDA, SVD, NMF

LDA는 클래스 분리를 최대화하는 지도 차원축소, SVD는 행렬의 저랭크 구조, NMF는 음수가 없는 데이터에서 부분 기반 표현을 만든다.

K-Means

각 점과 중심의 제곱거리 합을 줄인다. 구형이고 비슷한 크기의 군집에 강하며 스케일과 이상치에 민감하다.

Mean Shift

데이터 밀도가 높은 봉우리를 중심으로 군집을 찾는다. 군집 수를 직접 주지 않지만 bandwidth가 결과를 크게 좌우하고 데이터가 많으면 느리다.

실루엣과 해석

실루엣 계수는 같은 군집 안의 응집도와 가장 가까운 다른 군집과의 분리도를 비교한다. 높은 점수도 업무적으로 의미 없는 군집을 보장하지 않는다.

RFM

Recency, Frequency, Monetary는 고객 행동을 세 축으로 요약한다. 긴 꼬리를 log1p로 완화하고 표준화한 뒤 군집화하며, 해석은 다시 원 단위 평균으로 돌아와 수행한다.

3. 기법 비교와 선택

기법	지도 여부	주요 목적	핵심 제약
PCA	비지도	분산 보존과 압축	선형, 스케일 민감
LDA	지도	클래스 분리	라벨 필요, 축 수 제한
Truncated SVD	비지도	희소 행렬 저랭크 표현	중심화 없이 동작
NMF	비지도	양수 데이터의 부분 기반 표현	입력이 음수가 아니어야 함
K-Means	비지도	거리 기반 군집	군집 수 필요, 구형 가정
Mean Shift	비지도	밀도 봉우리 탐색	bandwidth 민감, 계산량 큼

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_PCA	Iris를 2차원으로 축소하고 클래스별 분포 시각화	축의 의미는 원 특성 loading과 설명분산비로 해석
02_LDA_SVD / 03_SVD_NMF	같은 Iris 표현을 여러 축소 기법으로 비교	라벨 사용 여부와 입력 제약이 결과 차이의 출발점
04_KMeans_MeanShift	Iris와 합성 데이터에서 중심 기반/밀도 기반 군집 비교	알고리즘 가정과 데이터 형태가 맞아야 라벨 대응이 좋아짐
05_Cluster_evaluation	군집 수 2~5의 실루엣 다이어그램 비교	평균 점수와 각 군집 내부 분포를 함께 확인
군집화_김양일	온라인 소매를 정제하고 RFM, log1p, 표준화, K-Means, PCA 시각화 수행	군집 번호가 아니라 Recency/Frequency/Monetary 원 단위 평균으로 고객군에 이름 부여

4. 실전 적용 기준

판단 체크리스트

시각화가 목적이면 PCA 2축, 분류 전처리면 교차검증 안에서 축소 성능을 평가한다.

희소 텍스트 행렬에는 중심화가 필요한 PCA보다 Truncated SVD가 실용적이다.

K-Means 전에는 스케일과 긴 꼬리, 극단값을 점검한다.

군집 수는 실루엣 점수와 군집 크기, 업무 활용 가능성을 함께 보고 결정한다.

최소 코드 패턴

```
rfm_log = np.log1p(rfm[["Recency", "Frequency", "Monetary"]])
X = StandardScaler().fit_transform(rfm_log)
for k in range(2, 6):
    labels = KMeans(k, random_state=42).fit_predict(X)
    print(k, silhouette_score(X, labels))
```

→ log1p는 금액과 빈도의 긴 꼬리를 완화한다.

→ 최종 군집 이름은 labels 숫자가 아니라 원 단위 RFM 요약을 바탕으로 붙인다.

5. 실수 방지와 복습

자주 생기는 오류

- PCA 전에 스케일 차이를 무시하기
- 실루엣 평균이 가장 높다는 이유만으로 군집 수 확정하기
- 군집 번호 0, 1을 서열로 해석하기
- 표준화된 좌표의 중심을 그대로 고객 가치로 설명하기

스스로 설명해 보기

- ☐ PCA와 LDA의 가장 중요한 차이는 무엇인가?
- ☐ NMF 입력에 음수가 있으면 안 되는 이유는 무엇인가?
- ☐ K-Means가 긴 타원형 또는 크기가 다른 군집에 약한 이유는 무엇인가?
- ☐ RFM 군집을 원 단위로 되돌려 해석해야 하는 이유는 무엇인가?

DAY 핵심 요약

1	차원축소는 정보 표현, 군집화는 구조 탐색이라는 서로 다른 목적을 가진다.
2	군집 평가는 내부 점수와 업무 해석의 교집합에서 결정한다.
3	RFM 군집의 최종 결과는 알고리즘 라벨이 아니라 행동 특성에 기반한 고객 설명이다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.