

머신러닝

DAY8

GMM과 DBSCAN 군집화

군집이 구형이 아니거나 노이즈가 섞이면 중심 하나로 충분할까?

개념 · 비교 · 결과해석 · 실전판단 · 복습

수업일 2026-08-21 · 원본 노트북 기반 재구성

1. 한눈에 보는 DAY

K-Means의 거리 중심 관점에서 벗어나 GMM의 확률 분포와 DBSCAN의 밀도 연결을 비교한다. 데이터의 모양, 밀도, 노이즈 여부에 따라 알고리즘을 고르는 날이다.

오늘의 핵심 질문

군집이 구형이 아니거나 노이즈가 섞이면 중심 하나로 충분할까?

문제 해결 흐름

1 형태/밀도 시각화	2 스케일 조정	3 알고리즘 가정 선택	4 하이퍼파라미터 점검	5 안정성과 해석 평가
----------------	-------------	--------------------	--------------------	--------------------

핵심 키워드

Gaussian Mixture	Soft assignment	DBSCAN	eps	Noise
------------------	-----------------	--------	-----	-------

2. 핵심 개념

GMM

여러 가우시안 분포가 데이터를 생성했다고 가정하고 각 점이 구성요소에 속할 확률을 추정한다. 공분산으로 타원형 군집을 표현할 수 있다.

Soft assignment

predict는 최종 군집을 주지만 predict_proba는 소속 확률을 준다. 경계의 불확실성을 활용할 수 있다는 점이 K-Means와 다르다.

DBSCAN

반경 eps 안에 min_samples 이상의 이웃이 있는 점을 핵심점으로 보고 밀도 연결된 영역을 확장한다. 군집 수를 미리 정하지 않고 노이즈를 -1로 표시한다.

eps와 min_samples

eps가 너무 작으면 노이즈가 늘고, 너무 크면 군집이 합쳐진다. min_samples가 커지면 핵심점 기준이 엄격해진다. 거리 기반이므로 스케일링이 중요하다.

알고리즘 가정

K-Means는 중심과 구형 거리, GMM은 확률적 타원, DBSCAN은 연결된 고밀도 영역을 가정한다. 점수보다 데이터 기하와 가정의 적합성이 먼저다.

3. 기법 비교와 선택

기법	군집 수	잘 맞는 형태	노이즈	약점
K-Means	사전 지정	비슷한 크기의 구형	별도 처리 없음	비선형 경계와 이상치에 약함
GMM	사전 지정	타원형 확률 분포	확률은 주지만 노이즈 라벨 없음	가우시안 혼합 가정과 초기값 민감
DBSCAN	자동	임의 형태의 밀도 연결	-1로 탐지	밀도가 크게 다른 군집과 고차원에서 어려움

노트북 실험에서 읽어야 할 것

노트북	무엇을 읽나	어떻게 해석하나
01_GMM	Iris와 변형된 blob에서 GMM과 K-Means 비교	타원형으로 늘어난 데이터에서 공분산을 쓰는 GMM이 형태를 더 유연하게 표현
01_GMM	target별 군집 라벨 개수 비교	군집 번호는 클래스 번호와 직접 일치하지 않으므로 최적 대응 후 해석
02_DBSCAN	Iris에서 eps 0.6/0.8과 min_samples 8/16 비교	작은 파라미터 변화로 노이즈와 군집 병합이 달라짐
02_DBSCAN	동심원 데이터에서 K-Means, GMM, DBSCAN 비교	중심 기반 모델이 나누기 어려운 비선형 구조를 DBSCAN이 밀도 연결로 분리

4. 실전 적용 기준

판단 체크리스트

타원형 겹침과 불확실성이 중요하면 GMM을 우선 검토한다.

불규칙한 형태와 노이즈 탐지가 중요하면 DBSCAN을 검토한다.

DBSCAN 전에 표준화하고 k-distance 그래프로 eps 후보를 찾는다.

고차원에서는 거리 집중 현상 때문에 차원축소 또는 다른 군집 방법을 함께 검토한다.

최소 코드 패턴

```
X_scaled = StandardScaler().fit_transform(X)
labels = DBSCAN(eps=0.5, min_samples=8).fit_predict(X_scaled)
noise_ratio = np.mean(labels == -1)
cluster_count = len(set(labels)) - (1 if -1 in labels else 0)
```

→ 군집 수와 함께 노이즈 비율을 기록해야 파라미터 변화를 해석할 수 있다.

→ eps는 원 데이터 단위가 아니라 스케일링된 거리 공간에서 의미를 가진다.

5. 실수 방지와 복습

자주 생기는 오류

- 군집 라벨 숫자를 정답 클래스와 직접 비교하기
- 스케일링 없이 eps 값을 조정하기
- 노이즈가 적을수록 항상 좋은 결과라고 판단하기
- GMM의 소속 확률을 실제 정답 확률로 해석하기

스스로 설명해 보기

- ☐ GMM이 K-Means보다 타원형 군집에 유리한 이유는 무엇인가?
- ☐ DBSCAN에서 -1 라벨은 무엇을 의미하는가?
- ☐ eps를 키울 때 군집 수와 노이즈는 일반적으로 어떻게 변하는가?
- ☐ 밀도가 서로 크게 다른 두 군집에서 DBSCAN이 어려운 이유는 무엇인가?

DAY 핵심 요약

1	군집 알고리즘 선택은 데이터 모양과 밀도 가정의 선택이다.
2	GMM은 불확실한 소속, DBSCAN은 노이즈와 비선형 연결에 강점이 있다.
3	파라미터 평가는 군집 수, 노이즈 비율, 안정성, 업무 해석을 함께 본다.

원본 노트북의 전체 코드는 기존 코드 중심 PDF에서 확인하고, 이 자료는 개념 이해와 결과 해석을 위한 복습본으로 사용하세요.